

Raport

Analiza metod ensemble learning

Grupa 1

02.06.2025

Spis treści

1	Wstęp	2
2	Metodologia	3
2.1	Zbiory danych	3
2.2	Preprocessing danych	3
3	Modelowanie	6
3.1	Wybór modeli	6
4	Porównanie modeli ensemble	7
4.1	Protokół oceny	7
4.2	Szczegółowe porównanie modeli ensemble	9
4.3	Dodatkowe analizy	16
5	Podsumowanie i wnioski	27
6	Bibliografia	29

1 Wstęp

Cel projektu

Celem projektu jest porównanie skuteczności trzech najpopularniejszych technik ensemble learning (bagging, boosting, stacking) w zadaniach klasyfikacyjnych i regresyjnych oraz analiza wpływu ich parametrów na odporność modelu na overfitting.

Zdefiniowanie problemu oraz motywacja stojąca za projektem

Współczesne problemy uczenia maszynowego, zarówno w zadaniach klasyfikacyjnych, jak i regresyjnych, charakteryzują się rosnącą złożonością oraz obecnością dużych i często niejednorodnych zbiorów danych. W takich warunkach pojedyncze modele predykcyjne, mimo swojej prostoty i szybkości działania, mogą nie być wystarczająco dokładne.

Ensemble learning [5], to technika polegająca na łączeniu kilku różnych modeli w celu uzyskania lepszej jakości predykcji niż w przypadku pojedynczego modelu. Metody ensemble mogą poprawiać zarówno dokładność predykcji, jak i ogólną odporność modelu na przeuczenie (overfitting).

Najpopularniejsze metody ensemble learning:

- Bagging [1], polega na budowaniu wielu modeli na losowych podzbiorach danych z replikacją (bootstrapping) i uśrednianie ich predykcji.
- Boosting [4], który polega na sekwencyjnym uczeniu kolejnych modeli, koncentrujących się na błędach poprzednich.
- Stacking [8], polega na szkoleniu różnych modeli, a następnie wykorzystaniu ich wyników jako danych wejściowych do nowego modelu, uczącego się jak najlepiej wykorzystać wyniki poszczególnych algorytmów.

Motywacją do realizacji projektu jest chęć dokładnego zbadania i porównania skuteczności tych trzech metod w kontekście rzeczywistych zadań klasyfikacyjnych i regresyjnych.

Konkretnie, staramy się odpowiedzieć na następujące pytania:

Które podejście zapewnia najniższy błąd predykcyjny dla każdego zestawu danych? Czy istnieją spójne wzorce (np. boosting wyróżnia się na danych wie-

lowymiarowych, bagging rozwija się na danych zaszumionych), które mogą informować o przyszłym wyborze modelu?

2 Metodologia

2.1 Zbiory danych

W celu przeprowadzenia eksperymentów wybrano sześć różnych zbiorów danych zróżnicowanych pod względem liczby obserwacji, liczby cech oraz stopnia nieliniowości zależności.

Airfoil Self Noise, zbiór danych dotyczący hałasu emitowanego przez skrzydła samolotu w zależności od parametrów przepływu powietrza.

California Housing, zbiór regresyjny, w którym celem jest przewidywanie ceny domów w Kalifornii.

Energy Efficiency, dane opisujące zapotrzebowanie na energię cieplną budynków, zawierające cechy takie jak powierzchnia, liczba pięter.

Friedman1, syntetyczny zbiór danych generowany losowo zgodnie z funkcją wyrażoną wzorem $y = 10 \cdot \sin(\pi x_1 x_2) + 20 \cdot (x_3 - 0.5)^2 + 10 \cdot x_4 + 5 \cdot x_5 + \varepsilon$, gdzie x_i oznacza i -tą kolumnę macierzy X oraz $\varepsilon \sim \mathcal{N}(0, 1)$. Macierz $X \in \mathbb{R}^{5000 \times 20}$ jest generowana losowo, gdzie każda z jej kolumn x_i zawiera niezależne próby z rozkładu jednostajnego $\mathcal{U}(0, 1)$.

Friedman3, syntetyczny zbiór danych, generowany losowo zgodnie z funkcją wyrażoną wzorem $y = \tan^{-1} \left(\frac{x_1}{x_2} \right) + \varepsilon$, gdzie x_i oznacza i -tą kolumnę macierzy X oraz $\varepsilon \sim \mathcal{N}(0, 0.1)$. Macierz $X \in \mathbb{R}^{200 \times 4}$ jest generowana losowo, gdzie każda z jej kolumn x_i zawiera niezależne próby z rozkładu jednostajnego $\mathcal{U}(0, 1)$.

Regression, zbiór regresyjny generowany za pomocą funkcji *make_regression*. Macierz cech $X \in \mathbb{R}^{1000 \times 10}$ jest generowana losowo, gdzie każdy element x_{ij} jest niezależną próbą z rozkładu normalnego standardowego $x_{ij} \sim \mathcal{N}(0, 1)$ dla $i = 1, \dots, 1000$, $j = 1, \dots, 10$.

2.2 Preprocessing danych

Przed rozpoczęciem modelowania wykonano standardowe kroki przetwarzania danych.

Brakujące obserwacje oraz obserwacje odstające

Żaden ze zbiorów nie posiadał brakujących danych, zatem możemy skupić

Zbiór danych	Liczba obserwacji	Liczba cech	Źródło
Airfoil Self Noise	1503	5	UCI
California Housing	20640	8	sklearn
Energy Efficiency	768	8	UCI
Friedman1	5000	20	wygenerowany z sklearn
Friedman3	200	4	wygenerowany z sklearn
Regression	1000	10	wygenerowany z sklearn

Tabela 1: Charakterystyka zbiorów danych użytych w eksperymentach.

się na obserwacjach odstających. W zbiorach "Friedman1" oraz "Friedman3" obserwacje odstające są obecne tylko w zmiennych celu (target), ponieważ zbiory są generowane syntetycznie, to wartości odstające reprezentują zamierzoną strukturę szumu. Usunięcie lub zmodyfikowanie ich mogłoby sztucznie zmniejszyć błąd modelu. Dlatego bardziej odpowiednie jest zachowanie ich w niezminionej postaci. W zbiorze "Airfoil Self Noise" usunięto wartości odstające, ponieważ nie odpowiadały one naturalnym obserwacjom i najprawdopodobniej były błędami pomiarowymi. Ponadto zidentyfikowano outliersy także w zbiorze "California Housing", jednak z uwagi na odporność modeli obserwacje te nie zostały usunięte, natomiast w zbiorze "Energy Efficiency" nie ma obserwacji odstających. Przechodząc do zbioru "Regression", zidentyfikowane obserwacje odstające są skrajnymi, ale poprawnymi losowaniami z prawdziwego rozkładu, a nie błędami wprowadzania danych. Usunięcie ich sztucznie zmniejszyłoby wariancję danych wejściowych.

Inżynieria cech

W wyniku analizy EDA, przeprowadzonej dla każdego ze zbiorów, zdecydowaliśmy się dodać do zbiorów nowe zmienne.

"Friedman1":

`feature_0 * feature_1`, `(feature_2)2`, `(feature_2)2 - feature_2`.

Dodaliśmy powyższe zmienne, ponieważ odpowiadają one składnikom funkcji generującej dane w syntetycznym zbiorze Friedman1, gdzie m.in. występuje składnik $\sin(\pi * \text{feature}_0 * \text{feature}_1)$ oraz nieliniowy wpływ $(\text{feature}_2 - 0.5)^2$. Uwzględnienie tych przekształceń pozwala modelowi uchwycić nieliniowość i interakcje między zmiennymi, które są ważne dla dokładnego odwzorowania zależności pomiędzy cechami a zmienną objaśnianą.

"Friedman3":

`feature_1 * feature_2`, `(feature_1)2`, `(feature_2)2`, `feature_2_bin`, oraz trzy cechy binarne: `feature_2_low`, `feature_2_med`, `feature_2_high`.

Dodaliśmy interakcję `feature_1 * feature_2`, ponieważ w zbiorze "**Friedman3**" podstawowy sygnał pochodzi z nieliniowej zależności obu tych zmiennych i chcieliśmy ją jawnie ująć. Wprowadzenie wielomianowych cech drugiego stopnia ma na celu przybliżenie zakrzywionych relacji (np. sinusoidalnej części funkcji), których nie uchwyciłby model liniowy. Dodatkowo podział `feature_2_bin` na trzy koszyki i kodowanie one-hot pozwala wychwycić progowe, skokowe efekty tej zmiennej.

"Airfoil Self Noise":

`f * delta, (delta)2, (alpha)2`.

Dodaliśmy interakcję `f * delta`, aby uwzględnić wzajemny wpływ częstotliwości drgań i amplitudy przemieszczenia na generowany hałas. Wprowadzenie cechy kwadratowej `(delta)2` pozwala uchwycić nieliniowy efekt amplitudy przemieszczenia, który ma wyraźny wpływ na poziom dźwięku. Dodatkowo dodanie `(alpha)2` umożliwia modelowi lepsze odwzorowanie zakrzywionej zależności między kątem natarcia a emisją hałasu.

"California Housing":

`MedInc * RoomsPC, (MedInc)2, HouseAge, MedInc Quartile Bands, HouseholdDensity`.

Dodaliśmy interakcję `MedInc * RoomsPC`, aby uchwycić wzajemny wpływ mediany dochodów i składu gospodarstwa domowego na cenę nieruchomości. Wprowadzenie cechy `(MedInc)2` pozwala modelowi uwzględnić nieliniowy wpływ poziomu dochodów, a `HouseAge` odwzorowuje zmienność wartości związanej z wiekiem budynków. Dodatkowo podział `MedInc` na kwartyle (`MedInc Quartile Bands`) umożliwia wychwycenie progowych efektów zmian dochodów, natomiast `HouseholdDensity` mierzy gęstość zaludnienia gospodarstw domowych i jej wpływ na rynek mieszkaniowy.

"Energy Efficiency":

`Surface Area * OverallHeight, Surface_to_Volume_Ratio, Wall_to_Roof_Ratio, Height_to_Wall_Ratio, Wall Area, Glazing Area * Orientation, Glazing Area * Glazing Area Distribution, Surface Area * Relative Compactness` oraz przekonwertowano `Orientation` oraz `Glazing Area Distribution` na cechy binarne.

W celu głębszego zrozumienia wpływu geometrii i konstrukcji budynków na ich zużycie energii, wprowadziliśmy zmienne takie jak iloczyn powierzchni do całkowitej wysokości (`Surface Area * Overall Height`) oraz stosunek powierzchni do objętości (`Surface_to_Volume_Ratio`), co pozwoliło na uchwycenie, jak kompaktowość budynku i jego gabaryty wpływają na efektywność

energetyczną. Dodaliśmy również wskaźniki kształtu, takie jak `Wall_to_Roof_Ratio` i `Height_to_Wall_Ratio`, aby odzwierciedlić proporcje ścian i dachu, które są kluczowe dla strat ciepła. Włączyliśmy także interakcje cech, np. `Glazing Area * Orientation` i `Glazing Area * Glazing Area Distribution`, aby zbadać synergiczny wpływ różnych aspektów, takich jak powierzchnia przeszkleń i ich usytuowanie, na bilans energetyczny budynku. Wprowadzenie `Surface Area * Relative Compactness` ma na celu uchwycenie złożonego efektu wzajemnego oddziaływania tych dwóch kluczowych parametrów.

W syntetycznych zbiorach danych oprócz cech informacyjnych, generowane są również cechy nadmiarowe. Są to kolumny macierzy X , które nie wpływają na wartość zmiennej docelowej y i służą do symulowania zmiennych zakłócających.

Ponadto dla zbioru "**Airfoil Self Noise**" zastosowano analizę głównych składowych (PCA) na zmiennych `alpha` i `delta` tworząc nową cechę `alpha_delta_pc1`. Zastosowano także transformację logarytmiczną `log1p` dla zmiennych `f` oraz `delta`.

Podobnie dla "**California Housing**" przeprowadzono redukcję wymiarowości za pomocą analizy głównych składowych (PCA), aby połączyć pary silnie skorelowanych zmiennych: `Latitude` i `Longitude` w cechę `Geo1` oraz parę `AveRooms` i `AveBedrms`, jako `RoomsPC`. Zastosowano także transformację logarytmiczną `log1p` dla zmiennych `Population`, `AveRooms` oraz `AveBedrms`.

3 Modelowanie

3.1 Wybór modeli

Z uwagi na ewentualne, nadmierne skomplikowanie eksperymentu, zdecydowano na zastosowanie po jednej reprezentatywnej metodzie dla każdego rodzaju podejścia ensemble.

- Jako metodę Baggingu wybrano Random Forest [2], jako klasyczny model wykorzystujący losowe podpróbki danych i cech.
- Dla Boostingu wykorzystano bibliotekę XGBoost [3], czyli wydajną implementację gradient boosting trees.
- Natomiast w Stackingu jako model nadrzędny użyto Ridge Regression [6], natomiast modelami bazowymi były: Random Forest, XGBoost oraz OLS [7] (zwykła regresja liniowa minimalizująca błąd L2).

Dla każdego z sześciu zbiorów danych przeprowadzono osobną selekcję najlepszego modelu oraz jego hiperparametrów. Proces ten przebiegał według następującego schematu:

1. Dane podzielono na zbiór treningowy (90 %) oraz testowy (10 %).
2. Dobór hiperparametrów prowadzono wyłącznie na zbiorze treningowym, wykorzystując powtarzaną k -krotną walidację krzyżową do oceny każdego kandydata:
 - dla modeli baggingowych i boostingowych zastosowano **TPE sampler** (Tree-structured Parzen Estimator) ukierunkowany na minimalizację średniego RMSE obliczanego ze wszystkich foldów i powtórzeń,
 - dla regresji Ridge (meta-learnera w stackingu) użyto **GridSearch** z identyczną procedurą przekrojów,
 - najczęściej stosowano schemat $k = 10$ z 2 – 3 powtórzeniami, a w niektórych eksperymentach $k = 5$ z 2 – 3 powtórzeniami.
3. Zestaw hiperparametrów o najniższym średnim RMSE posłużył do ponownego wytrenowania modelu na całym zbiorze treningowym.
4. Tak wytrenowany model końcowy został oceniony na wydzielonym zbiorze testowym (nie była to jedyna forma oceny modeli; szczegóły porównania i dodatkowych metryk znajdują się w Sekcji 4).

4 Porównanie modeli ensemble

Porównanie modeli przeprowadzono przy użyciu dwuetapowego protokołu oceny, aby zapewnić rzetelną i uczciwą ocenę zdolności uogólnienia modeli.

4.1 Protokół oceny

1. Walidacja krzyżowa na zbiorze treningowym

Dla każdego zbioru danych wykonano walidację krzyżową 10-krotną na zbiorze treningowym (z wyłączeniem końcowego zbioru testowego). Dla wszystkich modeli zastosowano te same podziały danych i ten sam seed losowy, aby zapewnić bezpośrednią porównywalność wyników. W trakcie walidacji modele były ponownie trenowane (oczywiście każdy model trenowano z zestawem hiperparametrów, który okazał się najlepszy w procesie ich strojenia).

Dla każdego foldu i każdego modelu obliczono trzy metryki: RMSE, MAE oraz współczynnik determinacji R^2 .

2. Ewaluacja na zbiorze testowym

Po wyborze i tuningu modeli, przeprowadzono ostateczną ewaluację na zbiorze testowym (10%), który nie był używany ani do trenowania, ani do tuning parametrów. Każdy model generował predykcje na zbiorze testowym, wykorzystując wcześniej wytrenowaną wersję.

Obliczono RMSE, MAE oraz R^2 na zbiorze testowym dla każdego modelu.

Metryki oceny modeli

Poniżej przedstawiono metryki używane do oceny jakości modeli w eksperymencie:

RMSE (Root Mean Squared Error)

To pierwiastek kwadratowy z błędu średnio-kwadratowego. Mierzy średni błąd przewidywań, kładąc nacisk na większe błędy. Niższe wartości świadczą o lepszym dopasowaniu.

MAE (Mean Absolute Error)

Oblicza średnią wartość bezwzględnej różnicy między wartościami rzeczywistymi a przewidywanymi. Jest łatwy do interpretacji i wyrażona w tych samych jednostkach co zmienna docelowa.

Współczynnik R^2 to miara proporcji wariancji zmiennej docelowej wyjaśnionej przez model.

Wartość R^2 zawiera się w przedziale od $-\infty$ do 1, gdzie 1 oznacza idealne dopasowanie, a wartości bliższe zero (lub ujemne) wskazują na słabą jakość modelu.

Podsumowanie protokołu oceny

Wyniki walidacji krzyżowej umożliwiają analizę statystyczną i ranking modeli w oparciu o powtarzalne próbkowanie danych treningowych. Z kolei ocena na zbiorze testowym stanowi ostateczną miarę jakości predykcji, niezależną od procesu wyboru modelu i tuningu hiperparametrów.

Oba etapy ewaluacji zostały zastosowane dla każdego modelu i każdego zbioru danych.

4.2 Szczegółowe porównanie modeli ensemble

Wizualizacja wyników

Dla każdego zbioru danych zamieszczono tabelę porównującą wyniki modeli Bagging, Boosting i Stacking ([Table 2](#)).

Tabela zawiera wyniki na zbiorze treningowym dla metryk: RMSE, MAE oraz R^2 oraz wyniki na zbiorze testowym (10%). Dodatkowo widnieje kolumna zawierająca tzw. lukę nadmiernego dopasowania (*over-fitting gap*). Najlepsze wartości w tabeli są wyróżnione pogrubieniem, co ułatwia szybkie porównanie.

Regression - 10-Fold + Test

	Model	RMSE_KFold	MAE_KFold	R2_KFold	RMSE_Test	MAE_Test	R2_Test	OverfitGap_RMSE
0	Rf	58.621 ± 4.397	43.516 ± 2.988	0.882 ± 0.014	56.460	42.615	0.904	-2.160
1	Xgb	17.309 ± 2.794	12.813 ± 1.488	0.990 ± 0.003	15.124	12.134	0.993	-2.184
2	Stack	5.410 ± 0.595	4.122 ± 0.334	0.999 ± 0.000	4.612	3.665	0.999	-0.798

Friedman1 - 10-Fold + Test

	Model	RMSE_KFold	MAE_KFold	R2_KFold	RMSE_Test	MAE_Test	R2_Test	OverfitGap_RMSE
0	Rf	0.811 ± 0.027	0.634 ± 0.020	0.972 ± 0.003	0.817	0.634	0.972	+0.006
1	Xgb	0.531 ± 0.015	0.420 ± 0.014	0.988 ± 0.001	0.515	0.410	0.989	-0.016
2	Stack	0.811 ± 0.027	0.634 ± 0.020	0.972 ± 0.003	0.817	0.634	0.972	+0.006

Friedman3 - 10-Fold + Test

	Model	RMSE_KFold	MAE_KFold	R2_KFold	RMSE_Test	MAE_Test	R2_Test	OverfitGap_RMSE
0	Rf	0.313 ± 0.074	0.249 ± 0.053	0.402 ± 0.156	0.291	0.240	-0.307	-0.022
1	Xgb	0.305 ± 0.074	0.242 ± 0.057	0.433 ± 0.158	0.228	0.178	0.201	-0.077
2	Stack	0.314 ± 0.074	0.248 ± 0.053	0.387 ± 0.197	0.308	0.246	-0.460	-0.006

California Housing - 10-Fold + Test

	Model	RMSE_KFold	MAE_KFold	R2_KFold	RMSE_Test	MAE_Test	R2_Test	OverfitGap_RMSE
0	Rf	0.597 ± 0.012	0.409 ± 0.007	0.734 ± 0.012	0.592	0.401	0.721	-0.005
1	Xgb	0.553 ± 0.014	0.381 ± 0.006	0.772 ± 0.014	0.550	0.375	0.759	-0.003
2	Stack	0.618 ± 0.012	0.424 ± 0.007	0.715 ± 0.012	0.615	0.419	0.698	-0.003

Airfoil Self Noise - 10-Fold + Test

	Model	RMSE_KFold	MAE_KFold	R2_KFold	RMSE_Test	MAE_Test	R2_Test	OverfitGap_RMSE
0	Rf	1.555 ± 0.113	1.172 ± 0.070	0.942 ± 0.009	1.704	1.309	0.942	+0.149
1	Xgb	1.160 ± 0.133	0.800 ± 0.063	0.967 ± 0.009	1.271	0.861	0.968	+0.111
2	Stack	1.183 ± 0.118	0.833 ± 0.056	0.966 ± 0.008	1.326	0.936	0.965	+0.143

Energy Efficiency - 10-Fold + Test

	Model	RMSE_KFold	MAE_KFold	R2_KFold	RMSE_Test	MAE_Test	R2_Test	OverfitGap_RMSE
0	Rf	0.453 ± 0.078	0.315 ± 0.047	0.998 ± 0.001	0.520	0.371	0.997	+0.068
1	Xgb	0.439 ± 0.069	0.314 ± 0.041	0.998 ± 0.001	0.522	0.378	0.997	+0.083
2	Stack	0.448 ± 0.081	0.317 ± 0.049	0.998 ± 0.001	0.522	0.384	0.997	+0.075

Tabela 2: Tabela wydajności modeli

Ponadto wygenerowano tabelę zbiorczą wskazującą najlepsze modele w podziale na zbiory danych (Table 3).

Dataset	Best_RMSE	Best_MAE	Best_R2
0 regression	Xgb	Xgb	Stack
1 friedman1	Xgb	Xgb	Xgb
2 friedman3	Xgb	Xgb	Xgb
3 california_housing	Xgb	Xgb	Xgb
4 airfoil_self_noise	Xgb	Xgb	Xgb
5 energy_efficiency	Rf	Rf	Rf


Tabela 3: Podsumowanie zbiorcze

Przedstawione zostały również wykresy słupkowe (Figure 1) oraz wykresy pudełkowe rozkładów wyników z walidacji krzyżowej (Figure 2), które wizualizują porównanie modeli w sposób intuicyjny.


Analiza wyników modeli regresyjnych, bazująca na metrykach zestawu testowego oraz rozkładach metryk z walidacji krzyżowej, ujawnia, że nie ma jednego modelu konsekwentnie osiągającego najlepsze wyniki we wszystkich testowanych zestawach danych. Potwierdza to zasadę, iż wybór optymalnego algorytmu jest ściśle zależny od specyfiki analizowanego problemu oraz charakterystyki danych.

Szczegółowa analiza wykazała, że model **XGB** generalnie osiągał najmniejsze wartości RMSE i MAE oraz największe R^2 na większości zbiorów danych. Wyjątkiem był zbiór **Energy Efficiency**, gdzie wszystkie modele prezentowały porównywalne wartości metryk, co utrudnia jednoznaczne wskazanie najlepszego modelu wyłącznie na podstawie tego wykresu.

Co więcej, zaobserwowano zmienność w relacji między metrykami uzyskanymi na zestawie testowym a rozkładami metryk z walidacji krzyżowej. W niektórych przypadkach, takich jak zbiory **Regression** i **Energy Efficiency**, wyniki te były spójne, co świadczy o stabilności danego modelu. Natomiast w innych, przykładem czego jest zbiór **Friedman3**, znaczne rozbieżności, a zwłaszcza szeroki rozrzut w walidacji krzyżowej dla niektórych modeli, mogą wskazywać na niestabilność modelu lub szczególną charakterystykę danego zestawu testowego, wymagającą dalszej analizy.



Rysunek 1: Metryki zestawu testowego według modelu




Rysunek 2: Wykresy pudełkowe rozkładu CV według metryk

Kolejnym krokiem było wygenerowanie porównawczych wykresów słupkowych dla różnych modeli i zbiorów danych, pokazujących ich "Overfitting


Gap" (Figure 3). To różnica między oceną na zbiorze treningowym, a testowym, pomaga nam zidentyfikować, które modele mają problem z overfittingiem.

Na wykresie **Test RMSE - CV RMSE** dla zbiorów **Regression**, **Friedman3** i **California Housing** zarówno RF, jak i XGB osiągają ujemne wartości różnicy, co oznacza nieznacznie lepsze wyniki na zestawie testowym niż w walidacji krzyżowej (konserwatywna estymacja błędu przez CV). W przypadku czysto liniowego zbioru **Regression** zauważamy jednak, że modele drzewiaste często niedoszacowują krańcowych wartości, ponieważ źle ekstrapolują zależności liniowe. W **Airfoil Self-Noise** i **Energy Efficiency** dodatnie wartości dla XGB (oraz nieznacznie dla Stack) wskazują na pewien poziom przeuczenia, gdy model radzi sobie gorzej na danych testowych niż w CV. Metoda Stack konsekwentnie redukuje tę rozbieżność i zapewnia najbardziej zrównoważoną generalizację.

Dodatkowo załączono wykresy przedstawiający rozkłady reszt (różnic między przewidywaniami modeli a wartościami rzeczywistymi) dla różnych modeli na zbiorze testowym każdego z analizowanych danych (Figure 4). Ogólnie modele RF generują najszersze rozkłady reszt z ciężkimi ogonami, XGB redukuje liczbę skrajnych błędów, a Stack dostarcza najbardziej skupione i symetryczne histogramy reszt, co wskazuje na najlepszą uogólnialność. Dla zbiorów **California Housing** i **Friedman1** obserwujemy wąskie, niemal normalne rozkłady, natomiast w **Airfoil Self-Noise** i **Energy Efficiency** wciąż występują pewne ogony, choć wyraźnie zmniejszone w XGB i Stack. Stacking konsekwentnie zapewnia najstabilniejsze predykcje z minimalną liczbą odchyleń skrajnych.



Rysunek 3: Overfitting Gap



Rysunek 4: Rozkłady reszt

Automatyczna interpretacja najlepszych modeli dla wszystkich zbiorów danych

Pętla iterująca wyświetla nazwę zbioru oraz raportuje najlepsze modele pod kątem metryk RMSE, MAE, R^2 oraz najmniejszej różnicy overfittingu.

Tabela 4: Podsumowanie najlepszych modeli dla różnych zbiorów danych

Zbiór danych	Najniższy RMSE	Najniższy MAE
Regression	Xgb	Xgb
Friedman1	Xgb	Xgb
Friedman3	Xgb	Xgb
California Housing	Xgb	Xgb
Airfoil Self Noise	Xgb	Xgb
Energy Efficiency	Rf	Rf

Tabela 5: Podsumowanie najlepszych modeli dla różnych zbiorów danych

Zbiór danych	Najwyższy R^2	Najmniejsza różnica overfit RMSE
Regression	Stack	Stack
Friedman1	Xgb	Rf
Friedman3	Xgb	Stack
California Housing	Xgb	Xgb
Airfoil Self Noise	Xgb	Xgb
Energy Efficiency	Rf	Rf

4.3 Dodatkowe analizy

Stabilność modelu

Aby ocenić stabilność modeli, obliczono odchylenie standardowe metryk RMSE, MAE oraz współczynnika determinacji R^2 na podstawie wyników walidacji krzyżowej dla każdego modelu i zbioru danych.

Wyniki zostały zaprezentowane w tabeli (Figure 5), a następnie zilustrowane za pomocą siatki wykresów słupkowych (Figure 6), gdzie każdy wiersz odpowiada jednemu zbiorowi danych, a każda kolumna jednej metryce.


Analiza odchyleń standardowych metryk ujawniła, że stabilność modeli różni się znacząco w zależności od analizowanego zbioru danych. Model XGB okazał się najbardziej stabilnym algorytmem, konsekwentnie dostarczając spójnych wyników w większości zestawów danych. Odchylenie standardowe dla XGB było najmniejsze na zbiorach **Friedman1** oraz **Energy Efficiency**, co świadczy o jego wysokiej odporności na zmienność podziałów danych.

Stacking również charakteryzuje się bardzo dobrą stabilnością, często dorównując lub nawet przewyższając XGB w niektórych przypadkach, czego przykładem jest najniższe odchylenie standardowe na zbiorze **Regression**.

Natomiast **Random Forest**, choć ogólnie solidny, może wykazywać większą niestabilność, zwłaszcza w specyficznych, być może bardziej złożonych zestawach danych, a najlepiej pod względem odchylenia standardowego poradził sobie na zbiorach **Airfoil Self Noise** oraz **California Housing**. Należy podkreślić, że na zbiorze **Friedman3** wszystkie trzy modele uzyskały podobne wartości odchylenia standardowego.

12	airfoil_self_noise	Rf	0.119	0.074	0.009
13	airfoil_self_noise	Stack	0.125	0.059	0.009
14	airfoil_self_noise	Xgb	0.141	0.066	0.010
9	california_housing	Rf	0.012	0.007	0.013
10	california_housing	Stack	0.013	0.007	0.013
11	california_housing	Xgb	0.015	0.007	0.014
15	energy_efficiency	Rf	0.083	0.050	0.001
16	energy_efficiency	Stack	0.085	0.052	0.001
17	energy_efficiency	Xgb	0.073	0.043	0.001
3	friedman1	Rf	0.028	0.021	0.003
4	friedman1	Stack	0.028	0.021	0.003
5	friedman1	Xgb	0.016	0.014	0.001
6	friedman3	Rf	0.078	0.055	0.165
7	friedman3	Stack	0.078	0.055	0.208
8	friedman3	Xgb	0.078	0.060	0.167
0	regression	Rf	4.634	3.149	0.015
1	regression	Stack	0.627	0.352	0.000
2	regression	Xgb	2.945	1.569	0.003

Rysunek 5: Odchylenie standardowe metryk



Rysunek 6: Odchylenie standardowe metryk - wykresy

Względna klasyfikacja modeli

Dla każdego zbioru danych oraz każdej metryki na zbiorze testowym (RMSE, MAE, R^2) przypisano rangi modelom (1 = najlepszy, 3 = najgłupszy). Niższe wartości RMSE i MAE oznaczają lepsze wyniki, natomiast wyższe wartości R^2 są pożądane.


Tabela (Figure 7) przedstawia, który model najczęściej osiąga najlepsze wyniki, co ułatwia identyfikację najskuteczniejszych metod.










		RMSE_Rank	MAE_Rank	R2_Rank
Dataset	Model			
Relative Performance Ranking (1 = best)				
airfoil_self_noise	Rf	3	3	3
	Stack	2	2	2
	Xgb	1	1	1
california_housing	Rf	2	2	2
	Stack	3	3	3
	Xgb	1	1	1
energy_efficiency	Rf	1	1	1
	Stack	2	3	1
	Xgb	2	2	1
friedman1	Rf	2	2	2
	Stack	2	2	2
	Xgb	1	1	1
friedman3	Rf	2	2	2
	Stack	3	3	3
	Xgb	1	1	1
regression	Rf	3	3	3
	Stack	1	1	1
	Xgb	2	2	2


Rysunek 7: Względna klasyfikacja modeli

Rozkład błędów i reszt

Dla wybranych zbiorów danych przedstawiono histogramy rozkładu reszt (różnicy między wartościami przewidywanymi a rzeczywistymi) dla każdego modelu. Uwidaczniają one zarówno tendencyjność modeli, jak i zachowanie się reszt w ogonie rozkładu. Wszystkie modele (Random Forest, XGBoost i Stacking) generują generalnie podobne rozkłady reszt dla większości zbiorów danych, co sugeruje zbliżoną jakość dopasowania. Wyjątkiem jest zbiór Friedman3, dla którego histogramy są bardziej nieregularne i rozproszone, niezależnie od użytego modelu. Może to wynikać z faktu, że Friedman3 to niewielki zbiór danych, przez co szacunki reszt są mniej stabilne i bardziej podatne na losowe odchylenia.









Rysunek 8: Rozkład błędów i reszt

Rozrzut wartości rzeczywistych, a przewidywanych

Dla tych samych zbiorów danych przedstawiono wykresy rozrzutu, na których porównano wartości rzeczywiste zmiennej docelowej z wartościami przewidywanymi przez każdy model na zbiorze testowym. Dzięki temu możemy zidentyfikować błędy systematyczne oraz ewentualne przesunięcia (bias) w predykcjach modeli. Dla zbioru **Regression** widać, że RF ma największy rozrzut punktów wokół przekątnej, XGB znacząco poprawia dopasowanie, a **Stack** niemal idealnie odtwarza wartości rzeczywiste. Dla zbiorów **Friedman1** wszystkie modele osiągają dobrą zgodność, przy czym **Stack** delikatnie redukuje systematyczne odchylenia w krańcowych obserwacjach. Dla **Friedman3** natomiast wszystkie modele poradziły sobie dość słabo, na co wpłynął fakt, iż ten zbiór był najmniej liczny (200 obserwacji) ale również zawierał najtrudniejszą zależność nieliniową. Dlatego też żaden z modeli nie mógł dobrze wyuczyć się tych danych. W rzeczywistych zbiorach **Airfoil**, **Self Noise** i **Energy Efficiency** różnice są mniejsze – wszystkie modele dobrze odwzorowują dane, ale XGB zapewnia najszczelniejszy przyrost zgodności z najdrobniejszymi zmianami zmiennej docelowej. W przypadku zbioru **California Housing** wszystkie modele poradziły sobie bardzo podobnie, w większości niedoszacowywały największych wartości, co jest związane z faktem, że znacząca większość posiadłości z tego zbioru miała wartości zmiennej celu w przedziale [150,000, 300,000] dolarów. Ponadto, dla zbioru **California Housing** widać wiele niedoszacowanych wartości 5 (skalowane 500,000 dolarów). Wynika to z faktu, że domyślnie ten zbiór miał ucięte wartości zmiennej celu na 500,000 dolarów. Stąd żaden model nie mógł nauczyć się dobrze wartości większych niż 500,000 i często ich niedoszacowywał.





Rysunek 9: Rozrzutu wartości rzeczywistych vs przewidywanych


Analiza przeuczenia

Dla każdego zbioru danych i modelu obliczono tzw. lukę przeuczenia (overfitting gap), za daną wzorem $\text{Gap} = \text{RMSE}(\text{test}) - \text{Średnie RMSE}(\text{CV})$. Dodatnia wartość oznacza, że model uzyskał gorszy wynik na zbiorze testowym niż w walidacji krzyżowej, co może świadczyć o przeuczeniu.

Została wygenerowana tabela (Figure 10) z wartościami luk przeuczenia dla każdego modelu i zbioru danych oraz siatka wykresów słupkowych (Figure 11) ilustrujących skalę przeuczenia.

Model	Rf	Stack	Xgb
Dataset			
Overfitting Gap (Test RMSE - Mean CV RMSE)			
airfoil_self_noise	0.149	0.143	0.111
california_housing	-0.005	-0.003	-0.003
energy_efficiency	0.067	0.074	0.083
friedman1	0.006	0.006	-0.016
friedman3	-0.022	-0.006	-0.077
regression	-2.161	-0.798	-2.185

Rysunek 10: Analiza przeuczenia - tabela





Rysunek 11: Analiza przeuczenia

Istotność cech

Wygenerowano dodatkowo siatkę wykresów przedstawiających porównanie, które cechy są najważniejsze w prognozowaniu dla każdego modelu i zbioru.

Na podstawie wykresów można zauważyć, że zarówno **Random Forest (Rf)**, jak i **XGBoost (Xgb)** wyodrębniają podobne cechy jako istotne, jednak XGBoost często silniej koncentruje wagę na jednej lub dwóch zmiennych, ignorując pozostałe bardziej niż Random Forest. Ponadto w zbiorach syntetycznych (jak Friedman1) modele skutecznie wykrywają dodane interakcje i przekształcenia, co potwierdza ich zdolność do identyfikowania nieliniowych zależności.





Rysunek 12: Istotność cech

5 Podsumowanie i wnioski

Ostatecznie otrzymaliśmy najlepsze modele według RMSE na zbiorze testowym. Jeśli była sytuacja, gdy dwa modele miały podobne RMSE, to decydowała wartość MAE.

Dataset	Best Test-Set Performer*
regression (1 k, synth.)	XGB (lowest RMSE/MAE)
friedman1 (5 k, synth.)	XGB
friedman3 (200, synth.)	XGB
california housing (20 k, real)	XGB
airfoil self-noise (1.5 k, real)	XGB
energy efficiency (768, real)	RF

Rysunek 13: Najlepsze modele

Wnioski dla poszczególnych zbiorów

Regression

Model XGB uzyskał najniższe wartości błędów, natomiast Stacking nieznacznie przeważał pod względem współczynnika determinacji R^2 .

Friedman1

Na dużym, wysokowymiarowym zbiorze syntetycznym XGB osiągnął wyraźną przewagę, uzyskując o około 5% lepsze wyniki niż kolejne modele.

Friedman3

Pomimo ograniczonej liczby próbek (200), XGB zachował pozycję lidera, choć różnice między modelami były niewielkie.

California Housing

XGB zdecydowanie zdeklasował konkurencję, notując ponad 10% przewagi w metryce RMSE względem kolejnych modeli.

Airfoil Self-Noise

Różnice były subtelne, lecz XGB nieznacznie przewyższył zarówno Random Forest, jak i Stacking (ok. 3% różnicy w RMSE).

Energy Efficiency

Najlepszy wynik osiągnął model Random Forest (ok. 2% przewagi w RMSE), podczas gdy XGB wykazał oznaki lekkiego przeuczenia.

Ogólne obserwacje

Boosting okazał się najbardziej niezawodną i skuteczną metodą, szczególnie w przypadku dużych i złożonych zbiorów danych.

Bagging to szybka, solidna baza, która może dominować w bardziej uporządkowanych, średniej wielkości zbiorach.

Stacking rzadko pokonuje XGB pod względem ogólnych wyników, ale bywa korzystny przy maksymalizacji R^2 . Trzeba jednak liczyć się z jego wyższym kosztem obliczeniowym i większą złożonością.

6 Bibliografia

Bibliografia

- [1] Leo Breiman. “Bagging predictors”. W: *Machine Learning* 24.2 (1996), s. 123–140.
- [2] Leo Breiman. *Random forests*. T. 45. 1. Springer, 2001, s. 5–32.
- [3] Tianqi Chen i Carlos Guestrin. “XGBoost: A scalable tree boosting system”. W: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (2016), s. 785–794.
- [4] Yoav Freund i Robert E Schapire. “A decision-theoretic generalization of on-line learning and an application to boosting”. W: *Journal of computer and system sciences* 55.1 (1997), s. 119–139.
- [5] Trevor Hastie, Robert Tibshirani i Jerome Friedman. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springer, 2009.
- [6] Arthur E Hoerl i Robert W Kennard. “Ridge regression: Biased estimation for nonorthogonal problems”. W: *Technometrics* 12.1 (1970), s. 55–67.
- [7] Douglas C Montgomery, Elizabeth A Peck i G Geoffrey Vining. *Introduction to Linear Regression Analysis*. Wiley, 2012.
- [8] David H Wolpert. “Stacked generalization”. W: *Neural networks* 5.2 (1992), s. 241–259.